

未命名2

1. 核心组件简介

Ollama — 本地推理引擎 (Inference Engine)

作用：

- Ollama 是一个轻量级的 **本地 LLM 推理框架 / 客户端**，支持在 Linux / Windows / macOS 等平台上 **一键运行和管理大型语言模型 (LLM)**。
- 它将模型下载到本地并启动成一个可通过 HTTP API 访问的推理服务（默认在 `localhost:11434`）——即使离线也能运行。
- 支持模型（如 Llama、Mistral、Qwen 等）的启动、管理和 API 调用，无需依赖云端服务。
(legacy-docs.dify.ai)

关键特点：

- 本地推理，最大限度保护数据隐私；
- API 服务化：启动模型后可通过统一 REST 接口调用；
- 支持自动拉取模型 + 量化模型优化显存占用。([知乎专栏](#))

✦ 总结：Ollama 是大模型运行的底层推理服务器

千问3 (Qwen3) — 大语言模型 (LLM)

作用：

- Qwen3 是阿里发布的新一代开源大型语言模型家族（通义千问系列最新成员）。
- 它本身是深度学习模型，用于理解自然语言、生成文本、SQL、推理等任务。([CSDN](#))

核心特点：

- 支持 Dense & 混合专家 (MoE) 架构，可在不同规模参数下灵活部署；
- 提供丰富语言理解能力与较长上下文支持；
- 可搭配本地推理框架（如 Ollama）部署与调用。([CSDN](#))

✦ 总结：Qwen3 是大模型本体，它需要运行环境来执行推理任务

Dify — AI 应用开发 / workflow 平台

作用：

- Dify 是一个面向开发者和产品的 **低代码 / 可视化 AI 平台**，用于搭建聊天机器人、知识库问答、自动化任务等业务应用。
- 它管理大模型调用、知识库、workflow、向量数据库等功能，可将 LLM 能力集成到产品/服务中。 ([CSDN](#))


典型功能：

- 可视化流程编辑 & workflow 编排（类似图形化编程）；
- 支持 **与本地推理服务（如 Ollama）集成** 做大模型接入；
- 提供 Embedding、RAG、Agent 等能力，无需写大量代码；
- 可部署为本地服务（通常基于 Docker）。 ([CSDN](#))

📌 总结：Dify 是应用层平台，负责组织业务逻辑并调用模型

2. 三者之间的整体关系

下面是一种典型本地部署架构关系图：



关系解释：

- 1. **模型（如 Qwen3）是 AI 能力的核心**
Qwen3 提供语言理解和生成能力，本质上是一个大参数的神经网络。 ([CSDN](#))
- 2. **Ollama 是模型的运行环境与推理接口**
它在本地启动模型并提供简单 API，可以被上层调用。 ([legacy-docs.dify.ai](#))
- 3. **Dify 是业务应用层平台**
它不做实际推理，但作为协调层，调度 Ollama 提供的推理能力，并构建应用流程（如问答、聊天、任务自动化）。 ([CSDN](#))

3. 本地 AI 大模型基本架构

主要组件

组件	作用	关键功能
LLM 模型本体（如 Qwen3）	提供语义理解 + 生成能力	语言建模、推理、生成
推理引擎（如 Ollama）	执行模型推理	模型加载、API 服务、量化支持
应用平台（如 Dify）	提供 AI 应用开发与流程	图形化设计、RAG、API、知识库
基础设施层（Docker / Docker Compose）	容器化部署	容器隔离、统一部署 & 网络管理

构建本地部署架构（实战思路）

A) 部署 Ollama（本地模型推理）

- 1. **安装与启动 Ollama**
 - 下载对应平台版本；
 - 通过命令拉取模型，如：

```
ollama run qwen3:8b
```
 - 默认监听 localhost:11434 提供 API 服务。 ([legacy-docs.dify.ai](#))
- 2. **模型管理**
 - 使用命令 `ollama list` 查看已下载模型；

- 可以拉取不同模型（如 LLaMA, Mistral）。([legacy-docs.dify.ai](https://docs.dify.ai/legacy-docs.dify.ai))

部署完成后，Ollama 就是一个本地的大模型 API 服务

B) 部署 Dify（基于 Docker）

通常使用 Docker 或 Docker Compose 进行部署：

```
git clone https://github.com/langgenius/dify.git
cd dify/docker
cp .env.example .env
docker compose up -d
```

完成后，在浏览器访问：

```
http://localhost/install
```

进行初始化配置。([CSDN](https://www.csdn.net/))

C) 在 Dify 中接入 Ollama

1. 打开 Dify 控制台 → 设置 → 模型供应商；
 2. 添加 Ollama 作为模型提供者；
 3. 填写 Ollama 地址（如 <http://host.docker.internal:11434>）；
 4. 配置模型名称、上下文长度等参数；
 5. 保存并测试连接是否成功。([legacy-docs.dify.ai](https://docs.dify.ai/legacy-docs.dify.ai))
-

D) 构建业务应用或工作流

在 Dify 中，你可以通过可视化界面：

- 创建聊天机器人应用；
- 构建工作流（如自然语言查询数据库、生成代码等）；
- 结合 Embedding 生成向量，构建知识库检索；
- 使用 Agent 方式组织更复杂逻辑。

✦ 例如：创建 Chatflow → 调用本地模型 → 返回响应。

4. 架构特点 & 优势

优点	说明
隐私安全	数据不出本地服务器
可控性强	自主管理不同模型版本
成本低	避免云端付费/延迟
可扩展	与企业后端系统集成

5. 小结

- **Ollama**：本地推理服务（LLM 运行环境）
- **Qwen3 / 模型**：提供语言理解与生成能力
- **Dify**：AI 应用构建与逻辑层平台

它们在本地图 AI 生态中扮演：

➡ **模型 — 推理 — 应用** 三层分工，组合成 *安全可控、本地部署的 AI 系统*。 ([CSDN](#))

如果你需要，我还可以进一步给出 **实际部署命令脚本** 或 **示例项目代码**（如 Ollama + Dify 即时问答案例）。要不要？ 😊